

《人工智能导论》大作业项目报告

基于 Transformer 主干与大模型选择性复核的可解释谣言检测系统

Alrumer2026 — 人工智能导论课程大作业

小组名称：第九组

组长：杨镕铭-523031910294 24%

组员：许鸿铭-524031910314 28%

组员：刘锦文-525761910007 24%

组员：蒲梓瑜-524031910088 24%

提交日期：2026 年 6 月

摘要

谣言检测是自然语言处理和社会计算中的典型文本分类任务。本项目基于社交媒体英文推文数据集，构建了一个可解释的谣言检测系统。系统采用「强主干 + 选择性复核」的两阶段架构：第一阶段使用本地集成模型（基于词级/字符级 TF-IDF 特征与多个线性分类器加权融合）提供稳定的基础分类，准确率约为 88.78%。第二阶段为 FN-aware Selective Correction：仅对主干判为非谣言的样本进行风险排序，选取 Top-K 高风险候选，通过 TF-IDF 检索相似训练样本作为参考证据，再调用 DeepSeek Reasoner 进行保守复核，最终经过三层规则门控确定是否翻转。最终系统在验证集上达到 89.03% 的准确率，Oracle 上界模拟显示理论空间超过 90%。系统从本地模型特征、相似样本检索和 LLM 复核三个层面提供可解释信息，具备良好的可解释性和工程可控性。

1. 项目背景与问题定义

随着社交媒体平台的普及，突发事件相关信息在短时间内迅速传播。然而，未经证实的谣言和误导性信息也能快速扩散，可能导致严重的社会影响。因此，构建高效、可靠且可解释的谣言检测系统具有重要的现实意义。

谣言检测是自然语言处理中的典型文本分类任务。社交媒体谣言往往具有以下特点：（1）文本短，信息稀疏；（2）包含大量事件名、话题标签、链接和转述；（3）谣言与非谣言可能共享同一突发事件背景；（4）简单关键词方法容易误判客观新闻；（5）仅靠单一分类器容易漏检隐含的未证实断言、阴谋指控和煽动性表达。

因此，本项目没有采用单一模型直接完成最终判定，而是采用两阶段结构：第一阶段用强主干模型保证整体分类稳定性；第二阶段只对主干容易漏检的高风险非谣言预测样本进行选择复核。该策略特别针对当前验证集上的错误结构：主干模型假阳性较少，但假阴性较多，因此优化重点是在尽量不新增 FP 的前提下修复 FN。

2. 数据集与环境

2.1 数据集说明

项目使用 PHEME 谣言检测数据集，包含多个突发事件主题的英文推文。

数据集	样本数	谣言 (1)	非谣言 (0)	事件类别
训练集 train.csv	2840	1240 (43.7%)	1600 (56.3%)	7 类
验证集 val.csv	401	175 (43.6%)	226 (56.4%)	7 类

数据集包含以下字段：id（推文 ID）、text（推文内容）、label（0=非谣言，1=谣言）、event（事件主题类别）。类别分布基本均衡，适合二分类任务。


2.2 实验环境

环境	配置
运行环境	Python 3.13.9, Windows 11
语言模型 API	DeepSeek Reasoner (SJTU OpenAI-compatible API)
主要依赖	scikit-learn 1.9.0, numpy, pandas, joblib, requests
本地模型	TF-IDF + LogisticRegression/SGD/MultinomialNB 加权融合
检索器	TF-IDF (ngram_range=1-3, max_features=50000) + Cosine Similarity

3. 模型方法

3.1 总体架构

系统采用两阶段流水线架构。下图展示了完整的处理流程：



规则门控：

- 高置信谣言门控 ($\text{confidence} \geq 0.80$)
- 高相似度谣言例外 ($\text{top1_similarity} \geq 0.35$)
- 客观新闻保护 (objective-report 模式拦截)

↓

输出最终标签与可解释信息

3.2 模块拆解

3.2.1 文本预处理 (text_utils.py)

系统对输入推文进行轻量级预处理：（1）URL 归一化：将所有 `https?://` 链接映射为稳定占位符 URL；（2）HTML entity 解码：将 `&` 解码为 `and`，避免特殊字符干扰；（3）空白清洗：压缩多余空白、起始结末去除空白。小写化由后续的 TF-IDF 向量化器处理，保证流程透明。

3.2.2 本地集成模型 (hybrid_classifier.py)

本地模型基于 `joblib` 序列化的集成器件，内部包含多个分类器：词级 TF-IDF + 逻辑回归 (`word_lr`)、字符级 TF-IDF + SGD 分类器 (`char_sgd`)、词级 TF-IDF + 多项式本叶斯 (`word_nb`)、词+字符联合 TF-IDF + 逻辑回归 (`lr_union_c8`)。每个分类器输出概率后，按权重加权平均得到最终概率。此外还提供可解释词项特征提取功能，显示哪些词语对判断影响最大。

3.2.3 相似样本检索 (retriever.py)

系统使用 TF-IDF 向量化 + 余弦相似度从训练集中检索与待测文本最相似的 Top-K 样本。TF-IDF 向量化器配置：`analyzer=word`、`ngram_range=(1,3)`、`max_features=50000`、`sublinear_tf=True`。检索结果包含相似度分数、文本原文和真实标签，作为后续 LLM 复核时的 few-shot 证据。

检索结果示例：对于某条突发新闻推文，系统检索到的 top-3 相似样本均被标注为谣言，相似度分别为 0.2308、0.1649、0.1353，这为 DeepSeek 判断提供了参考依据。

3.2.4 DeepSeek 复核器 (llm_reranker.py)

DeepSeek Reasoner 复核器采用保守型二阶段 Prompt。系统角色设定为「保守型谣言复核器」，任务是判断一条英文推文是否应从非谣言翻转为谣言。具体要求：（1）如果文本是客观报道、视频标题、官方通报、现场描述或澄清，优先保持 0；（2）只有当文本存在明确未证实断言、阴谋指控、煽动性传播或谣言话术时，才允许输出 1；（3）不得仅因为相似样本中谣言比例高就判为谣言。

DeepSeek 复核器必须输出结构化 JSON：label（0 或 1）、confidence（0~1）、evidence_type（包含 objective_report、unverified_claim、conspiracy_accusation、sensational_claim、correction_or_denial、unclear）、should_flip（是否建议翻转）、reason（中文解释判断依据）。

```
class LLMReranker:
    def review(self, text, local_label, local_confidence,
               feature_cues, similar_examples):
        messages = self.build_prompt(
            text, local_label, local_confidence,
            feature_cues, similar_examples)
        content = self.client.chat(messages)
        parsed = self._extract_json(content)
        return {
            'label': parsed['label'],
            'confidence': parsed['confidence'],
            'evidence_type': parsed['evidence_type'],
            'should_flip': parsed['should_flip'],
            'reason': parsed['reason']
        }
```

3.3 小组成员其他工作

小组四位成员分别在不同分支上实现了多种谣言检测方案。以下是各分支的技术路线对比：

分支	主要技术	架构特点	准确率
main（本报告重点）	Transformer + 加权融合 + FN-aware + DeepSeek	两阶段结构，深度优化门控规则	89.03%
Karo942-patch-1	DistilBERT + RAG + DeepSeek LLM	三层架构，端到端训练	—
deng	独立模型组件	模块化设计，支持自由组合	—
yrongming	BiGRU + DistilBERT + RAG + LLM	集成模型 + 复合模型，多方案对比	86.03%

本报告重点介绍 main 分支的工作——基于 Transformer 主干与大模型选择性复核的两阶段架构，该方案融合了各位成员的经验并在此基础上进行了深度优化。

4. FN-aware 选择性修正策略

4.1 设计动机

主干模型当前错误结构为：FP = 10，FN = 35。如果直接降低分类阈值，虽然可能减少 FN，但往往会显著增加 FP。因此，本项目采用 FN-aware selective correction：只对主干预测为 0 的样本进行风险排序，只复核其中最像漏检谣言的少量样本，只在高置信条件下允许 0 → 1 翻转。

4.2 FN-risk Score 评分机制

系统为每个主干判为 0 的样本计算风险分数，综合以下信号：

信号	权重贡献	说明
transformer_prob_1	0.3 ~ 0.8	Transformer 对谣言类的概率，值越高越可疑
dedicated_prob_1	0.25 ~ 0.9	专用模型对谣言类的概率
knn_rumor_ratio_top3	0.65 ~ 1.0	Top-3 近邻中的谣言比例
knn_rumor_ratio_top5	0.35 ~ 0.55	Top-5 近邻中的谣言比例
knn_rumor_ratio_top7	0.35	Top-7 近邻中的谣言比例
top1_label+similarity	0.35 ~ 1.0	Top-1 近邻为谣言且相似度较高
base_prob_1	0.2 ~ 0.35	本地模型对谣言类的概率
非谣言减分惩罚	-0.35	Top-1 为非谣言且相似度 ≥ 0.35 时减分

风险分数越高的样本越容易被选入复核队列。默认配置为 top_k=20、review_threshold=0.55，即只复核 FN-risk 评分超过 0.55 的最高前 20 名候选。

4.3 Oracle 上界实验

为了判断该策略是否有理论提升空间，项目提供 oracle 模拟模式：用真实标签替代理想复核器。验证表明，Top-20 候选中确实包含足够的可修正 FN，理论上界为：accuracy = 90.27%，混淆矩阵 $\begin{bmatrix} 216 & 10 \\ 29 & 146 \end{bmatrix}$ ，恢复 FN = 6。这说明 90%+ 在候选层面是有机会的，关键在于真实复核器能否高精度识别这些 FN。

5. 翻转门控与规则保护

5.1 高相似度谣言例外

为了避免保守 prompt 过度抑制召回，系统加入高相似度谣言例外规则。只有同时满足以下所有条件时，才允许翻转：

- DeepSeek label = 1（判为谣言）
- should_flip = true（建议翻转）
- confidence $\geq$ 0.80（高置信度）
- evidence_type $\in$ {unverified_claim, conspiracy_accusation, sensational_claim}
- top1_label = 1（最相似训练样本为谣言）
- top1_similarity $\geq$ 0.35（相似度足够高）
- knn_rumor_ratio_top5 $\geq$ 0.20（近邻谣言比例足够高）

5.2 客观新闻保护规则

为了避免把客观新闻误判为谣言，系统加入客观新闻保护。以下模式会触发保护（即使样本位于高风险候选队列也不会被翻为谣言）：

- video:
- watch:
- raw video
- key moments
- statement from
- issued a statement
- prime minister says
- police confirm / police say
- official says
- calling for calm
- has accounted for
- last position
- was travelling from
- when it crashed

- crowd gathers
- stands by the front entrance
- turns the lights off

5.3 允许翻转的证据类型

证据类型	含义	是否支持翻转
objective_report	客观新闻报道	✗
unverified_claim	未经证实的断言	✓
conspiracy_accusation	阴谋指控	✓
sensational_claim	煽动性传播	✓
correction_or_denial	澄清或否认	✗
unclear	证据不足	✗

6. 实验结果与分析

6.1 Transformer 主干结果（基线）

主干模型在验证集上的基础表现如下：

指标	数值
准确率	88.78%
混淆矩阵	[[216, 10], [35, 140]]
TN / FP / FN / TP	216 / 10 / 35 / 140

6.2 各实验方案对比

实验方案	Accuracy	混淆矩阵	恢复 FN	新增 FP	说明
Transformer 主干	88.78%	[[216,10],[35,140]]	—	—	当前基线
DeepSeek 直接 Top-20	88.78%	[[213,13],[32,143]]	+3	+3	救回 3 FN 但新增 3 FP
保守 DeepSeek + 高置信门控	89.03%	[[216,10],[34,141]]	+1	0	有效控制 FP
最终方案完整版	89.03%	[[216,10],[34,141]]	+1	0	含高相似度例外+新闻保护

Oracle 上界	90.27%	[[216,10],[29,146]]	+6	0	理论最优解
-----------	--------	---------------------	----	---	-------

6.3 最终方案详细报告

类别	精确率	召回率	F1-score	支持数
非谣言 (0)	0.864	0.956	0.908	226
谣言 (1)	0.934	0.806	0.865	175
整体 (accuracy)		0.8903		401
宏观平均	0.899	0.881	0.886	401
加权平均	0.894	0.890	0.889	401




图 1：最终方案混淆矩阵

从结果可以看出：非谣言类别的召回率达到 0.956，说明系统在识别非谣言时非常保守，很少误报；谣言类别的精确率达到 0.934，说明系统判定为谣言的样本中绝大多数是正确的。混淆矩阵显示 FP = 10 且未新增，验证了选择性修正策略有效控制了误翻风险。

6.4 各事件类别准确率分析




图 2：各事件类别准确率对比

6.5 实验结论

通过实验可以得出以下结论：

- (1) 主干模型整体较强，FP 控制良好。主要问题是漏检了 35 条谣言样本，因此后续改进集中在 FN-aware selective correction。
- (2) 简单降低分类阈值会导致 FP 显著增加。DeepSeek 直接复核虽然救回了 3 条 FN，但同时新增了 3 条 FP，净收益为 0。
- (3) 保守复核 + 规则门控有效控制了误翻风险。当前最优方案救回了 1 条 FN，新增 FP 为 0。
- (4) Oracle 上界显示该方向具备超过 90% 的理论空间，说明当前的选择性修正策略方向是正确的。

7. 可解释性评估

系统从三个层面提供可解释性：

- ① 本地模型层：提取具有最高权重的词项特征，如 “word_breaking” 、 “word_conspiracy” 等，显示哪些词语影响了判断。例如对于某条突发新闻推文，模型提取的关键特征包括 word_reports、word_breaking、word_story 等。
- ② 检索层：返回 TF-IDF 检索的 Top-K 相似训练样本，包含文本内容、真实标签和相似度分数，提供对比参考。
- ③ LLM 复核层：DeepSeek 输出结构化的中文解释，并标明证据类型（如 conspiracy_accusation、objective_report），让用户理解每步判断的依据。

8. 项目总结

8.1 收获与心得

- (1) 掌握了基于 TF-IDF 和线性分类器加权融合的文本分类方法；
- (2) 学会了设计保守型 Prompt 来控制 LLM 输出质量，避免大模型过度自信的问题；
- (3) 理解了错误驱动优化的思想，从分析混淆矩阵开始，针对性地解决 FN 过多的问题，而不是盲目追求单一指标的最优化；
- (4) 实践了可解释 AI 系统的架构设计，从多个层面提供判断依据，具有良好的工程可用性。

8.2 存在问题及解决思路

- (1) 当前真实 DeepSeek 复核仍未稳定超过 90%。可考虑的改进方向：调整门控阈值、优化 Prompt 设计、引入多次复核机制、或考虑使用不同的大模型进行比较。
- (2) 相似度阈值和客观新闻保护规则需根据数据集校准。可引入自动参数搜索优化，对不同数据集自适应地调整阈值。
- (3) 当前仓库未包含完整训练流水线。可考虑将 Transformer 训练过程整合进来，支持更多实验和模型训练。
- (4) 如果换到新事件、新平台或新语言，需要重新评估 FN-risk 分布并调整相关参数。

8.3 课程建议

本次大作业设计合理，既要求基本的模型实现能力，又鼓励创新性的多模型融合。建议未来可以增加更多基础模型实验参考（如 BERT、RoBERTa 等），同时提供更详细的性能评估指标和可视化工具。此外，可以考虑增加可解释性的客观评估指标，以更好地衡量不同方案的可解释能力。

参考文献

- [1] PHEME 谣言检测数据集. <https://www.pheme.eu/>
- [2] Vaswani, A. et al. Attention Is All You Need. NeurIPS 2017.
- [3] DeepSeek. DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning. 2025.
- [4] 上海交通大学本地大模型 API. <https://models.sjtu.edu.cn/>
- [5] 机器学习实战：基于 TF-IDF 的文本分类. scikit-learn.